Indonesia AI
AI for Everyone, AI for Indonesia

Project 2

Text

Summarization

Use Case : liputan6.com

April 2025
Group C – Batch 10 NLP

Project Overview

*Berikut adalah **gambaran singkat dari project yang akan dilakukan**:*

Project Description

Project Text Summarization akan membuat ringkasan yang singkat, mudah dipahami kalimatnya dan memiliki informasi inti dari teks original secara otomatis. Sistem ini akan membantu mengurangi waktu membaca para eksekutif ketika memahami suatu dokumen penting dan rumit

Project Method

Pada proyek ini digunakan **algoritma Text summarization ,** disertai dengan **proses hyperparameter tuning** untuk mengoptimalkan kinerja masing-masing algoritma.

Project Output

Proyek ini untuk analisis teks untuk **membantu pengguna memahami isi dokumen atau artikel dengan lebih efisien melalui** model IndoBERT dalam melakukan Text Summarization

Business Objective

Hasil dari proyek ini diharapkan dapat memberikan manfaat bisnis, antara lain:

- **Membantu pengguna memahami isi dokumen atau artikel** dengan **lebih efisien** dan juga hanya berisi informasi yang penting sehingga **lebih efektif**

Project Member

Indonesia AI
AI for Everyone, AI for Indonesia

1

Irfan Gani Alim

2

Khaerani **Arista** Dewi

3

Agil Setiawan

4

Krisna **Fery** Rahmantya

5

Surya Dharma Putra

Project Flow

Indonesia AI
AI for Everyone, AI for Indonesia

1 Data & Business Understanding

Data Understanding & EDA	Exploratory Data Analysis for Text Sumarization
Contextual Understanding of the Dataset	Visualisasi and Distribusi Split Dataset
Text Cleaning	Compression Ratio per Split
Text Length Analysis	Tokenization + Lexical Overlap

Unigram, Bigram, Text Normalization, Count Sentences Article + Extractive

2 Data Preprocessing

- Konfigurasi Processing
- Tokenization Model
- Clean Article and Summary
- Preprocess per Data Frame
- Split data Train,Val, Test

3 Data Modeling

Data Modeling

IndoBERT

4 Model Evaluation

- Rogue 1
- Rogue 2
- Rogue L

5 Summary

Data Understanding

Indonesia AI
AI for Everyone, AI for Indonesia

1 Data Ingestion & Environment Setup

- Import library untuk:
  - Membaca archive .tar.gz
  - Memproses file JSON
  - Mengatur path agar rapi
  - Mengolah data menjadi DataFrame

Documentation:

Load Library

```python
import tarfile
import json
from pathlib import Path
import pandas as pd
```

```python
def to_text(x):
    if x is None:
        return None

    if isinstance(x, list):
        if len(x) > 0 and isinstance(x[0], list):
            return " ".join(" ".join(map(str, sent)) for sent in x)
        return " ".join(map(str, x))

    return str(x)
```

2 Data Parsing & Split Management

- Menyiapkan variabel penampung data per split (train, dev, test)
- Membaca .tar.gz, mengambil setiap file JSON, lalu mengelompokkan ke train/dev/test

Documentation:

```python
data_by_split = {
    "train": [],
    "dev": [],
    "test": []
}

n_ok = 0
n_bad_json = 0
n_unknown_split = 0
```

```python
try:
    with tarfile.open(archive_path, "r|gz") as tar:
        while True:
            try:
                member = tar.next()
            except (EOFError, tarfile.ReadError, OSError) as e:
                print(f"Warning: archive berhenti di tengah jalan -> {e}")
                print("Data yang sudah berhasil dibaca tetap dipakai.")
                break

            if member is None:
                break

            if not member.isfile() or not member.name.endswith(".json"):
                continue

            try:
                f = tar.extractfile(member)
                if f is None:
                    continue

                obj = json.load(f)

            except (json.JSONDecodeError, EOFError, OSError, tarfile.ReadError) as e:
                n_bad_json += 1
                print(f"Skip {member.name} karena JSON/file error: {e}")
                continue

            parts = Path(member.name).parts
            split = None
            for s in ["train", "dev", "test"]:
                if s in parts:
                    split = s
                    break
```

3 Data Integrity & Quality Checks

- Pengecekan file untuk memastikan tidak ada file yang rusak

Documentation:

```
Jumlah data per split:
train: 193883
dev  : 15920
test : 14834
```

```
Ringkasan pembacaan:
Berhasil dibaca : 224637
File JSON rusak : 0
Split tak dikenal: 0

Jumlah data per split:
train: 193883
dev  : 15920
test : 14834
```

4 Resource & Scalability Handling

- Downsize distribusi menjadi 60% untuk menghindari out of RAM saat tokenisasi
- Pengecekan hasil downsampling

Documentation:

```
Target ukuran train baru: 46131

Distribusi split setelah downsampling:
       count  percent
train  46131    60.00
dev    15920    20.71
test   14834    19.29

Distribusi segmen train sebelum vs sesudah:
         before_percent  after_percent  diff
segment
news              100.0          100.0   0.0
```

5 Data Preview

- Menampilkan contoh data

Documentation:

	id	url	clean_article
0	239502	https://www.liputan6.com/news/read/239502/knkt-selidiki-kecelakaan-merpati	Liputan6 . com , Jakarta : Dua anggota tim Komite Nasional Keselamatan Transportasi (KNKT) pada Rabu (5/8) pagi , berangkat dari Jakarta menuj...
1	215354	https://www.liputan6.com/news/read/215354/torres--kartu-truf-di-old-trafford	Posisi puncak klasemen masih diduduki Liverpool . Mereka unggul empat poin dari Chelsea di urutan kedua , dan lima poin dari Manchester United . N...
2	295725	https://www.liputan6.com/news/read/295725/tetap-bekerja-saat-lebaran	Liputan6 . com , Jakarta : Hari Raya Idulfitri biasanya dirayakan bersama keluarga atau sanak saudara . Namun , ternyata tidak semua orang bisa me...
3	222639	https://www.liputan6.com/news/read/222639/anggun-pulang-kampung	LAMA tak terdengar , penyanyi Anggun C . Sasmi yang selama ini menetap di Prancis , tiba-tiba sudah ada di Tanah Air . Selain kangen kampung halam...
4	124497	https://www.liputan6.com/news/read/124497/jakarta--i-great-sale--i--di-sejumlah-rumah-sakit	Liputan6 . com , Jakarta : Pemerintah DKI Jakarta menggelar Jakarta Great Sale selama satu bulan sejak 14 Juni hingga 14 Juli 2006 . Kali ini , pe...

	clean_summary	extractive_summary	source_file	segment
	Komite Nasional Keselamatan Transportasi berangkat menuju Oksibi , Papua , untuk menyelidiki penyebab jatuhnya pesawat Merpati .	[0, 1]	liputan6_data/canonical/train/239502.json	news
	Fernando Torres mengeluarkan pendapat mengenai persaingan ketat Liverpool dan Manchester United di Liga Premier . Torres tanpa sungkan percaya kal...	[1, 10, 7, 3]	liputan6_data/canonical/train/215354.json	news
	Penjaga palang pintu perlintasan kereta tetap bekerja saat Lebaran . Mereka harus berada di ruang 3x4 meter hanya ditemani radio , kipas angin , d...	[3, 7]	liputan6_data/canonical/train/295725.json	news
	LAMA tak terdengar , penyanyi Anggun C . Sasmi yang selama ini menetap di Prancis , tiba-tiba sudah ada di Tanah Air . Selain kangen kampung halam...	[0, 2, 1, 3]	liputan6_data/canonical/train/222639.json	news
	Pemerintah DKI Jakarta menggelar program potongan harga sepuluh persen khusus pemeriksaan Rontgen dan CT Scan . Program diskon ini tidak berlaku u...	[5, 6]	liputan6_data/canonical/train/124497.json	news

Exploratory Data Analysis

Indonesia AI
AI for Everyone, AI for Indonesia

1 Cek Distribusi Split Dataset

Distribusi dataset pasca downsampling **didominasi oleh data train (60%),** sehingga efisien dan aman untuk tokenisasi serta training, **sementara porsi dev dan test (~20% masing-masing)** tetap memadai untuk evaluasi model yang andal.

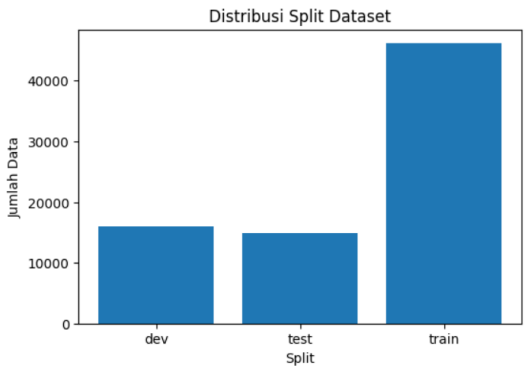

split	count	percent
dev	15920	20.71
test	14834	19.29
train	46131	60.00

Persentasi Split Data

2 Cek Distribusi Panjang Artikel

Distribusi panjang artikel menunjukkan pola right-skewed pada semua split, dengan variasi panjang yang besar dan keberadaan outlier sangat panjang, sementara **panjang summary relatif pendek dan stabil. Pola ini menegaskan karakteristik tugas summarization merangkum teks panjang menjadi ringkasan singkat dan kita akan menggunakan sentence level,** dengan batas maksimum sekitar 128 token yang dikirim agar beban komputasi tetap terkendali

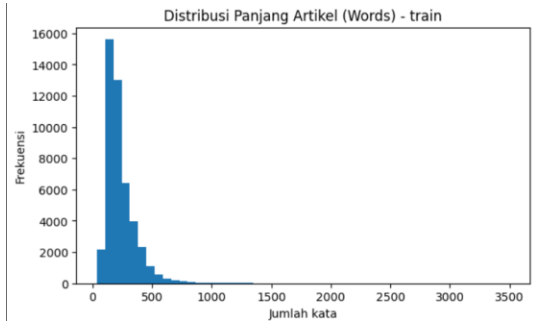

split	article_words_mean	article_words_median	article_words_min	article_words_max
dev	229.15	199.0	78	1841
test	222.60	192.0	74	3515
train	234.22	197.0	35	3496

Nilai mean yang konsisten lebih besar daripada median pada seluruh split

article_chars_mean	article_chars_median	article_chars_min	article_chars_max	summary_words_mean
1455.56	1268.0	465	11524	24.56
1403.34	1209.5	481	23124	26.01
1450.92	1222.0	239	20565	30.98

Rata-rata panjang summary berada di kisaran 24.56-30.98 kata, dengan median yang sangat dekat terhadap mean pada semua split

3 Cek Distribusi Panjang Summary

Distribusi panjang summary pada semua split lebih sempit dan stabil dibandingkan artikel, **dengan mayoritas berada pada kisaran 20–35 kata** serta nilai mean dan median yang berdekatan. Hal ini menunjukkan bahwa **ringkasan dalam dataset Liputan6 bersifat singkat, padat, dan relatif konsisten, dengan sedikit outlier terutama pada split train.** Temuan ini menegaskan bahwa proses summarization lebih menekankan **pemilihan informasi inti daripada variasi panjang dan struktur ringkasan.**

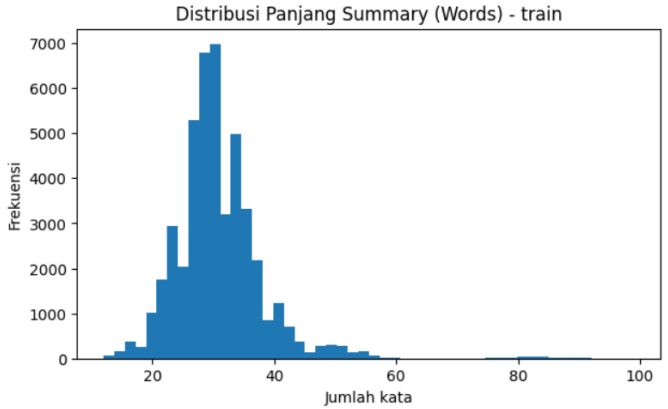

Exploratory Data Analysis

Indonesia AI
AI for Everyone, AI for Indonesia

4 Menghitung Compression Ratio

Compression ratio yang stabil pada kisaran 12–16% di seluruh split menunjukkan bahwa dataset ini menuntut tingkat peringkasan yang cukup tinggi, di mana artikel panjang harus diringkas menjadi output yang jauh lebih singkat. **Karakteristik ini mengindikasikan potensi kuat untuk pendekatan abstractive summarization,** meskipun evaluasi lanjutan terhadap lexical overlap tetap diperlukan untuk menentukan relevansi metode extractive.

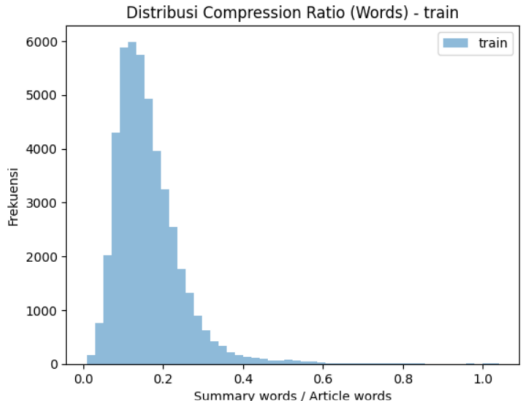

split	compression_words_mean	compression_words_median	compression_words_min	compression_words_max
dev	0.1225	0.1203	0.0149	0.3974
test	0.1351	0.1338	0.0083	0.3271
train	0.1632	0.1469	0.0092	1.0405

compression_chars_mean	compression_chars_median	compression_chars_min
0.1277	0.1260	0.0153
0.1429	0.1416	0.0077
0.1691	0.1527	0.0104

Compression ratio yang stabil pada kisaran 12–16% di seluruh split menunjukkan bahwa dataset ini menuntut tingkat peringkasan yang cukup tinggi,

5 Melakukan Pengecekan Overlap (Lexical/Source)

Lexical overlap yang tinggi di seluruh split menunjukkan bahwa meskipun dataset ini menuntut kompresi yang kuat, ringkasan tetap sangat bergantung pada kosakata artikel sumber. Jika dipertimbangkan bersama dengan compression ratio yang kecil, karakteristik ini mengindikasikan bahwa **dataset lebih extractive-friendly, sehingga pendekatan extractive summarization menjadi titik awal yang lebih aman dan sesuai dibanding langsung menggunakan abstractive.**

split	overlap_token_mean	overlap_token_median	overlap_token_min	overlap_token_max
dev	0.7920	0.8095	0.2222	1.0
test	0.8180	0.8333	0.3077	1.0
train	0.8667	0.8929	0.0625	1.0

overlap_unique_mean	overlap_unique_median	overlap_unique_min	overlap_unique_max	jaccard_mean
0.7822	0.8000	0.2222	1.0	0.1319
0.8076	0.8235	0.2143	1.0	0.1513
0.8588	0.8824	0.0625	1.0	0.1868

Hasil lexical overlap menunjukkan bahwa summary pada dataset ini memiliki kedekatan leksikal yang cukup tinggi dengan artikel sumber. Nilai `overlap_token_ratio` berada di kisaran `0.79-0.87` dan `overlap_unique_ratio` juga tinggi, sekitar `0.78-0.86`

6 Melakukan Pengecekan Unigram Dan Bigram Pada Artikel Dan Summary

Analisis unigram dan bigram menunjukkan bahwa **artikel masih mengandung token boilerplate khas media yang kurang bermakna secara semantik, sehingga perlu ditangani melalui domain stopwords khusus**. Sebaliknya, **summary sudah relatif bersih dari token media, sehingga distribusi kata yang tersisa lebih informatif dan layak dipertahankan** untuk menjaga kualitas representasi isi ringkasan.

	unigram	freq
0	com	41087
1	liputan6	40519
2	jakarta	39842
3	warga	30056
4	tim	26639
5	rumah	22832
6	baca	21849
7	polisi	19640
8	indonesia	19346
9	rp	18023
10	1	17427

	bigram	freq
0	liputan6 com	40359
1	com jakarta	15163
2	liputan 6	9258
3	6 sctv	8736
4	tim liputan	8525
5	rumah sakit	6441
6	jawa barat	5504
7	jawa timur	4733
8	jakarta pusat	3137
9	anak anak	3004
10	jakarta selatan	2719

	unigram	freq
0	warga	5673
1	jakarta	3697
2	rumah	3604
3	korban	3312
4	indonesia	3168
5	polisi	2957
6	pemerintah	2890
7	presiden	2665
8	orang	2660
9	kota	2537
10	rp	2462

	bigram	freq
0	rumah sakit	749
1	jawa barat	734
2	jawa timur	609
3	manchester united	481
4	minyak tanah	436
5	real madrid	419
6	anak anak	418
7	amerika serikat	411
8	1 0	411
9	jakarta selatan	401
10	warga desa	393

Exploratory Data Analysis

Melihat Jumlah Kalimat Artikel Dan Summary Per Split

Statistik jumlah kalimat menunjukkan kontras yang jelas antara artikel dan summary: artikel rata-rata terdiri dari sekitar 14–15 kalimat, sedangkan summary hanya sekitar 2 kalimat dan konsisten di semua split. **Pola ini menegaskan bahwa dataset dirancang untuk mengekstraksi atau merangkum sangat sedikit kalimat kunci dari artikel yang relatif panjang, sehingga menuntut ringkasan yang padat dan selektif.**

Jumlah kalimat yang dipilih untuk ringkasan ekstraktif konsisten di sekitar 2 kalimat pada semua split, menunjukkan bahwa informasi utama artikel umumnya dapat direpresentasikan oleh sangat sedikit kalimat sumber. **Pola ini memperkuat bahwa dataset ini secara alami mendukung pendekatan extractive summarization sebagai strategi yang efektif dan relevan.**

Berdasarkan EDA, dataset lebih tepat diposisikan sebagai extractive summarization karena meskipun compression ratio kecil, lexical overlap tetap tinggi dan ringkasan umumnya terbentuk dari sekitar 2 kalimat penting. Oleh karena itu, **eksperimen difokuskan pada pendekatan extractive dengan menggunakan IndoBERT**

split	article_sent_mean	article_sent_median	article_sent_min	article_sent_max
dev	15.00	13.0	4	122
test	14.43	12.0	5	197
train	15.15	13.0	2	308

Artikel rata-rata terdiri dari sekitar 14–15 kalimat,

summary_sent_mean	summary_sent_median	summary_sent_min	summary_sent_max
2.05	2.0	1	7
2.09	2.0	1	6
2.14	2.0	1	11

Summary hanya sekitar 2 kalimat dan konsisten di semua split.

split	extractive_sent_mean	extractive_sent_median	extractive_sent_min	extractive_sent_max
dev	2.11	2.0	2	7
test	2.11	2.0	2	5
train	2.26	2.0	2	11

Jumlah kalimat yang dipilih untuk ringkasan ekstraktif rata-rata berada di kisaran `2.11-2.26`

split	compression_words_mean	compression_words_median	overlap_token_mean	overlap_unique_mean	jaccard_mean	extractive_sent_mean	extractive_sent_median
dev	0.1225	0.1203	0.7920	0.7822	0.1319	2.11	2.0
test	0.1351	0.1338	0.8180	0.8076	0.1513	2.11	2.0
train	0.1632	0.1469	0.8667	0.8588	0.1868	2.26	2.0

Preprocessing

Indonesia AI
AI for Everyone, AI for Indonesia

01 Load & Rapikan Data

- Baca train / dev / test dari arsip .tar.gz
- Ambil kolom: clean_article, clean_summary, extractive_summary

02 Normalisasi Teks

- Hapus URL
- Rapikan whitespace & lowercase
- Rapikan tanda baca ringan

03 Bersihkan Boilerplate Domain

- 9 pola dihapus: liputan6.com, liputan 6, 6 sctv, tim liputan, baca/simak/lihat juga, selengkapnya, 00 wib
- Lead berita: Liputan6.com, Jakarta (LEAD_NEWS_PAT regex)
- Tujuan: model fokus ke isi, bukan format media

04 Split Artikel Jadi Kalimat

- Artikel dibersihkan ringan, lalu dipecah via regex fallback
- 1 artikel (1 baris) → list of sentences

05 Validasi Label Ekstraktif

- extractive_summary = indeks kalimat ringkasan bawaan dataset
- Pastikan: format list ✓ · indeks valid ✓ · tidak out-of-range ✓

06 Buang Data Tidak Layak

- Artikel dibuang jika: hasil split kosong, atau tidak ada label positif sama sekali

Preprocessing

Indonesia AI
AI for Everyone, AI for Indonesia

07 Cleaning Per Kalimat — Alignment Dijaga

- Setiap kalimat dibersihkan satu-satu
- Urutan & posisi kalimat tetap dijaga agar indeks extractive_summary tidak bergeser

08 Fallback untuk Kalimat Positif

- Kalimat berlabel 1 yang kosong setelah cleaning → tidak langsung dibuang
- Digunakan versi fallback ringan agar gold label tidak hilang

09 Buat Label Biner per Kalimat

- extractive_summary → label: 1 (terpilih) atau 0 (tidak)
- Setiap artikel punya list: [1, 0, 0, 1, 0, ...]

10 Buang Kalimat Kosong Non-Informatif

- Setelah label aman dibuat, baru kalimat kosong/noise dibuang
- Indeks positif diperbarui ke versi final siap model

11 Bangun Dataset Sentence-Level

- Tiap kalimat = 1 baris data
- Kolom: id · split · sent_idx · sentence_text · label · gold_k · reference_summary

Preprocessing = normalisasi teks + bersihkan boilerplate + split kalimat + jaga alignment label + bangun dataset klasifikasi per kalimat

Interna

Data Modelling

*Model yang kami pilih adalah **IndoBERT** dipilih karena dataset seluruhnya berbahasa **Indonesia** dan juga salah satu keluarga BERT. Selain itu, **IndoBERT** cocok untuk **sentence-level extractive summarization** karena mampu memahami konteks kalimat secara dua arah dan digunakan untuk **mengklasifikasikan** setiap kalimat sebagai **penting (1) atau tidak penting (0).***

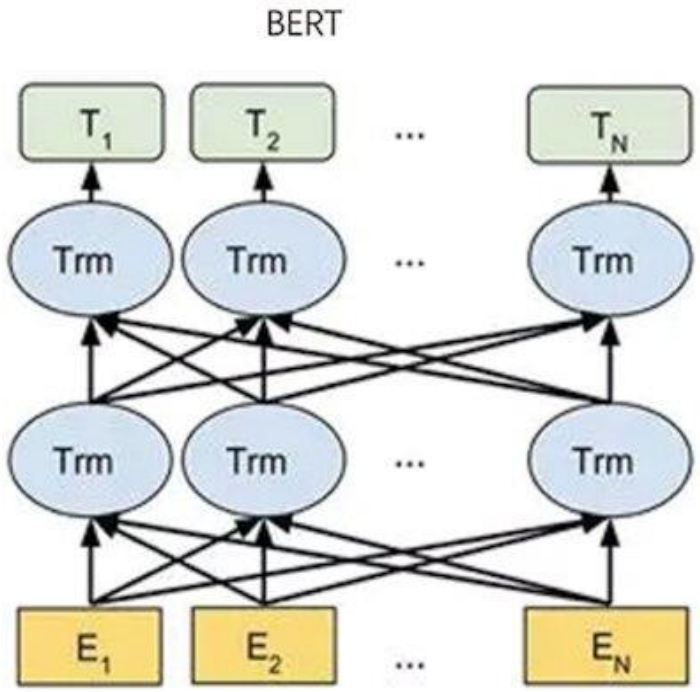

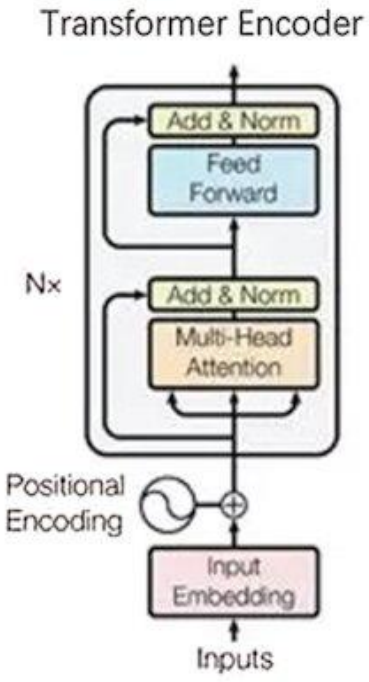

Keuntungan Arsitektur BERT

- **Input Embedding + Positional Encoding**
  - Token diubah menjadi vektor
  - **Positional Encoding** menjaga informasi urutan kata
  - Penting karena kalimat bergantung pada posisi kata
- **Tranformer Encoder**
  - Tiap layer memproses konteks kalimat secara dua arah
  - Cocok untuk memahami hubungan antarkata
- **Multi-Head Self-Attention**
  - Dapat **memperhatikan** kata lain yang relevan dalam kalimat
- **Feed Forward + Add & Norm**
  - Membuat pembelajaran lebih stabil di banyak layer
  - Membantu model membentuk representasi kalimat yang lebih kuat

*Pada projek kali ini, model diimplementasikan menggunakan **AutoModelForSequenceClassification** dengan **2 label** (num_labels = 2), sehingga tugasnya berupa **klasifikasi biner per kalimat**: kalimat penting untuk ringkasan **1** dan kalimat tidak penting **0**. Karena checkpoint yang digunakan adalah **indobenchmark/indobert-base-p2,** backbone yang dipilih otomatis adalah **IndoBERT berbasis BERT,** lalu ditambahkan s**equence classification head untuk tugas klasifikasi**. Umumnya, konfigurasi standar BERT Base diantaranya **hidden size 768**, **12 Transformer encoder layers, 12 attention heads, max position embeddings 512, dll***

Internal

Baseline IndoBERT

Indonesia AI
AI for Everyone, AI for Indonesia

Input

- **Input Unit:** Kalimat (sentence level)
- **Tokenizer:** Tokenizer IndoBERT
- **Max_len_sent:** 128 -> hasil EDA dan masih masuk akal
- **Padding:** Data Collator With Padding(dynamic padding/batch)

Baseline Training Config

- **learning_rate** : 2e-5 -> pembaruan model secepat apa
- **batch_size** : 64 -> jumlah data diproses
- **epochs :** 3 -> jumlah maks iterasi train
- **weight_decay :** 0.01 -> membantu mengurangi overfitting
- **warmup_ratio** : 0.1 -> fase pemanasan

Training Setup

- Evaluasi pada **dev/epoch**
- Best model berdasarkan **F1 score** terbaik
- **Early Stopping patience** : 1
- **Random seed** untuk menjaga **konsistensi**
- **Mixed precision:** fp16 jika CUDA tersedia

Evaluasi Akhir

- **Metric Klasifikasi:** accuracy, recall, precision, F1-score
- **Metric Summarization(utama):** ROUGE-1, ROUGE-2, ROUGE-L
- Ringkasan prediksi dibentuk dari skor kalimat tertinggi
- Jumlah kalimat prediksi mengikuti **oracle_k = gold_k**

```python
baseline_cfg = {
    "learning_rate": 2e-5,
    "batch_size": 64,
    "epochs": 3,
    "weight_decay": 0.01,
    "warmup_ratio": 0.1
}

baseline_trainer, baseline_result, baseline_dev_pred,
    cfg=baseline_cfg,
    run_name="indobert_baseline",
    train_ds=train_ds,
    dev_ds=dev_ds,
    tokenizer=tokenizer,
    dev_sent_df=dev_sent_df,
    test_sent_df=test_sent_df,
    use_oracle_k=True
)

print("Baseline result:")
for k, v in baseline_result.items():
    print(f"{k}: {v}")
```

Fine Tuning IndoBERT

*Pada tahap tuning, **arsitektur model** yang digunakan tetap sama dengan **baseline**, yaitu **IndoBERT** berbasis **AutoModelForSequenceClassification** untuk klasifikasi biner per kalimat. Dengan demikian, tidak ada perubahan pada backbone model maupun struktur head klasifikasi.*

Dampak Hyperparameter pada Fine-Tuning IndoBERT

- **Learning Rate**: Mengatur seberapa besar langkah update bobot
  - Naik -> belajar lebih cepat, tapi lebih berisiko tidak stabil
  - Turun -> lebih stabil, tapi lebih lambat
- **Batch size:** Menentukan jumlah sampel dalam satu update
  - Naik -> belajar lebih lama, tapi risiko overfitting
  - Turun -> lebih cepat, tapi bisa belum optimal
- **Epochs**: Menentukan berapa kali seluruh data dilalui saat training
  - Naik -> belajar lebih lama, tapi risiko overfitting
  - Turun -> lebih cepat, tapi bisa belum optimal
- **Weight decay :** Regularisasi untuk mengurangi overfitting
  - Naik -> regularisasi lebih kuat
  - Turun -> model lebih fleksibel, tapi lebih rawan overfitting
- **Warmup ratio :** Mengatur porsi langkah awal training dengan learning rate kecil
  - Naik -> awal training lebih stabil
  - Turun -> lebih cepat, tapi awal training bisa kurang halus

Explore Hyperpameter

- **Learning Rate**
- **Batch Size**
- **Epoch**

Best Model Configuration

- **Learning Rate:** 3e-5
- **Batch Size:** 16
- **Epoch**: 3
- **Weight Decay:** 0.01
- **Warmup Ratio:** 0.1

```python
search_space_3 = [
    {
        "learning_rate": 2e-5,
        "batch_size": 16,
        "epochs": 3,
        "weight_decay": 0.01,
        "warmup_ratio": 0.1
    },
    {
        "learning_rate": 3e-5,
        "batch_size": 16,
        "epochs": 3,
        "weight_decay": 0.01,
        "warmup_ratio": 0.1
    },
    {
        "learning_rate": 2e-5,
        "batch_size": 8,
        "epochs": 4,
        "weight_decay": 0.01,
        "warmup_ratio": 0.1
    }
]
```

*Perubahan pada tahap ini hanya difokuskan pada beberapa **hyperparameter training**, yaitu **learning_rate, batch_size, dan epochs**. Ketiga parameter ini dipilih karena paling berpengaruh terhadap stabilitas finetuning, kecepatan pembelajaran model,serta keseimbangan antara performa dan efisiensi training.*

Internal

Model Evaluation

Baseline IndoBERT

Epoch	Training Loss	Validation Loss	Accuracy	Precision	Recall	F1
1	0.363500	0.393241	0.855994	0.614237	0.107735	0.183317
2	0.352700	0.382538	0.856552	0.606693	0.124502	0.206606
3	0.327700	0.396552	0.852391	0.526951	0.156936	0.241845

Baseline menunjukkan **klasifikasi kalimat masih belum optimal**.

- Nilai accuracy mencapai 0.8524, tetapi **kurang representatif** karena data **tidak seimbang dan didominasi oleh label 0.**
- Nilai precision sebesar 0.5270 menunjukkan **prediksi suatu kalimat sebagai penting, sudah cukup tepat.**
- Tapi, recall yang rendah, 0.1569, yang **menujukan masih banyak kalimat penting yang terlewat.**
- Akibatnya, nilai FI juga masih rendah, yaitu 0.2418.
- **Secara umum, model baseline masih cenderung konservatif: cukup selektif saat memilih kalimat penting, tetapi belum mampu menangkap cukup banyak kalimat yang benar-benar relevan.**

```
Baseline result:
run_name: indobert_baseline
learning_rate: 2e-05
batch_size: 64
epochs: 3
weight_decay: 0.01
warmup_ratio: 0.1
dev_loss: 0.39655181765556335
dev_accuracy: 0.8523906576817243
dev_precision: 0.5269514873228189
dev_recall: 0.156935608537963
dev_f1: 0.24184533626534727
dev_rouge1: 26.13433821886454
dev_rouge2: 13.235660175717118
dev_rougeL: 22.629750952332234
dev_avg_rouge: 20.666583115637962
best_checkpoint: ./outputs/indobert_baseline\checkpoint-30903
test_rouge1: 30.15664646132391
test_rouge2: 16.399237402094137
test_rougeL: 25.79741956028046
test_avg_rouge: 24.1177678078995
```

Nilai ROUGE menunjukan bahwa mulai ada kemiripan antara refernce dan prediksi, tapi kualitas ringkasan belum maksimal
-> tahap tuning masih diperlukan

Hasil ROUGE menunjukkan baseline sudah menghasilkan ringkasan yang cukup masuk akal, tetapi masih perlu perbaikan.

- **ROUGE-1,** mencapai **0.2613** pada dev dan **0.3016** pada test, sudah menunjukkan bahwa **sebagian kata penting dari ringkasan referensi sudah berhasil tertangkap.**
- **ROUGE-2,** bernilai **0.1324** pada dev dan **0.1640** pada test, masih relatif rendah, model **belum terlalu kuat dalam menangkap kecocokan frasa**
- Sementara itu, **ROUGE-L,** bernilai mencapai 0.2263 pada dev dan **0.2580** pada test, menunjukkan bahwa **urutan informasi utama sudah cukup tertangkap**, meskipun belum optimal.

Internal

Model Evaluation

Tuned Model

Parameter	Dev	Test
ROUGE-1	29.476	30.156 ↑
ROUGE-2	15.865	16..399 ↑
ROUGE-L	25.503	25.797 ↑

Tuning ke-2 adalah model terbaik dengan konfigurasi:

- Learning_rate = 3e-05
- Batch_size = 16
- Epoch = 3
- Weight_decay = 0.01
- Warmup_ratio = 0.1

- Hasil ini menunjukkan bahwa model terbaik konfigurasi diatas memberikan **keseimbangan terbaik pada tahap validasi dan test.** Tuning ke-2 menghasilkan **ringkasan yang paling mendekati referensi** sehingga dipilih sebagai konfigurasi terbaik
- Dari tabel diatas, terlihat juga kenaikan yang konsisten pada seluruh metrik ROUGE di test, menunjukkan peningkatan performa model secara menyeluruh pada data yang belum pernah dilihat.

Baseline vs Tuned Model

Indonesia AI
AI for Everyone, AI for Indonesia

	model	rouge1	rouge2	rougeL	avg_rouge
0	IndoBERT Baseline	30.156646	16.399237	25.797420	24.117768
1	IndoBERT Tuned (best of 3)	33.685530 ↑	19.310103 ↑	28.630541 ↑	27.208725 ↑

Data test, model **IndoBERT Tuned** menunjukkan performa yang lebih baik dibanding **IndoBERT Baseline** pada seluruh metrik ROUGE.
Rouge1:
Baseline: 0.3016 -> Tuned: 0.3369,
Rouge2:
Baseline: 0.1640 -> Tuned: 0.1931,
RougeL`
Baseline: 0.2580 -> Tuned:`0.2863`.
avg_rouge`
Baseline: 0.2412 -> Tuned:`0.2721`

Hasil ini menunjukkan bahwa **proses tuning berhasil meningkatkan kualitas ringkasan yang dihasilkan pada data uji.** Dengan kata lain, **model hasil tuning lebih baik dalam menangkap kata-kata penting, frasa, dan urutan informasi utama dibanding konfigurasi baseline**.

Internal

Model Evaluation

Test Case Model: 20 sampel

Kesimpulan Kualitatif Berdasarkan 3 Contoh Prediksi

1. **Sample 12 -> cukup baik**
   - Model sudah menyoroti tokoh utama, yaitu **Hamzah Haz**, serta isu utama berupa **terorisme di Amerika Serikat, meskipun** detailnya tidak identik, inti topik masih tertangkap dengan cukup baik, menunjukkan bahwa model bisa memilih kalimat relevan jika artikel dan referensi masih dekat secara leksikal.
2. **Sample 1 -> cukup relevan, tetapi belum padat**
   - Model sudah menangkap topik utama tentang **Tommy Soeharto** dan kasus **kepemilikan senjata api, amunisi, dan bahan peleda, tetapi** belum menonjolkan detail penting seperti **durasi pencekalan selama setahun** dan **tanggal mulai berlakunya pencekalan,** menunjukkan bahwa model sudah ***on-topic,*** tetapi masih belum optimal merangkum secara padat .
3. **Sample 6 -> masih buruk**
   - Model hanya menghasilkan teks **"liputan6. liputan6."**, sedangkan ringkasan referensi justru membahas **pengamanan aset dan warga Amerika Serikat di Aceh, menunjukan** filtering belum sepenuhnya berhasil, karena boilerplate domain seperti **liputan6** masih lolos ke ringkasan akhir. Kasus seperti ini menjadi indikasi kuat bahwa ke depan perlu dilakukan **filtering dan preprocessing perlu dilakukan lebih ketat**

```
Sample 12
id: 19917
pred_summary:
wakil presiden hamzah haz mengecam tindakan terorisme yang menghancurkan gedung world tra
de center di new york dan pentagon di washington, amerika serikat. hamzah mengingatkan pe
merintah as agar tak buru-buru menuduh kelompok islam garis keras sebagai pelaku penyeran
gan.

reference_summary:
dalam pertemuan dengan pengurus pimpinan pusat pemuda muhammadiyah di istana wapres, wapr
es hamzah haz mengecam terorisme di amerika serikat. islam tak pernah membenarkan cara-ca
ra kekerasan.
```

```
Sample 1
id: 22405
pred_summary:
kejaksaan agung resmi mencekal hutomo mandala putera alias tommy soeharto untuk bepergian
ke luar negeri. pencekalan tommy alias ibrahim kali ini berkaitan dengan kepemilikan senj
ata api, amunisi, dan bahan peledak di apartemen cemara dan rumah di jalan alam segar iii
no.

reference_summary:
tommy soeharto kembali dicekal atas kasus kepemilikan senjata api, amunisi, dan bahan pel
edak. pencekalan kepada tommy selama setahun itu diberlakukan sejak 19 oktober 2001.
```

```
Sample 6
id: 21889
pred_summary:
liputan6. liputan6.

reference_summary:
maraknya aksi anti-amerika serikat di indonesia membuat aparat keamanan memperketat penga
manan seluruh aset dan warga as di aceh. jumlah pekerja asing di aceh sulit diprediksi.
```

Kesimpulan & Future Works

*Pendekatan **extractive summarization** berbasis **IndoBERT** sudah cukup efektif sebagai baseline awal untuk **dataset Liputan6,** tetapi masih terdapat ruang perbaikan pada sisi **data, preprocessing, dan eksplorasi model***

Kesimpulan

Dataset lebih cocok untuk extractive summarization

- EDA menunjukkan **lexical overlap** tinggi, **compression ratio** kecil, dan **extractive summary** umumnya hanya sekitar 2 kalimat.
- Ini berarti ringkasan cenderung singkat tetapi masih dekat secara leksikal dengan artikel sumber.

Model Terbaik

- **IndoBERT Tuned** dipilih sebagai model final karena memiliki performa **ROUGE** pada test set yang lebih baik dibanding **IndoBERT Baseline**, baik dari sisi **ROUGE-1, ROUGE-2, maupun ROUGE-L**, sehingga lebih representatif untuk menghasilkan ringkasan ekstraktif yang **lebih relevan** dan **mendekati referensi**

Model sudah cukup relevan, tetapi belum konsisten

- Secara **kualitatif**, model sudah mampu menangkap **topik utama pada banyak kasus.**
- Namun, masih ada kelemahan seperti **boilerplate yang lolos**, repetisi kalimat, dan ringkasan yang belum cukup padat.

Future Works

Menjalankan Indonesian RoBERTa

- **Menguji model RoBERTa** sebagai model pembanding yang sempat direncanakan, tetapi belum sempat dijalankan karena **keterbatasan waktu dan resource** untuk **arsitektur dynamic maskingnya** yang mungkin membantu.

Mencoba model extractive lain

- Mencoba menggunakan **varian BERT lain,** atau pendekatan **hierarchical encoder untuk dokumen yang lebih panjang.**

Menggunakan data train yang lebih besar

- Karena pada project ini data train **didownsample,** eksperimen berikutnya dapat mencoba **seluruh dataset** agar model memiliki **data belajar yang lebih kaya.**

Memperketat preprocessing dan post-processing

- Terutama untuk **menghapus boilerplate** seperti **liputan6, fragmen lokasi/lead berita, duplikasi kalimat,** dan **noise lain** yang masih lolos.

Mengembangkan strategi pemilihan kalimat

- Misalnya penentuan jumlah kalimat prediksi yang lebih adaptif, threshold probabilitas yang lebih optimal, atau **re-ranking** agar **ringkasan lebih fokus dan tidak redundan**.

Internal

Thank You

Group C – Batch 10 NLP